

2026 机器学习

课程报告 3

姓名：徐厚泽

学号：26113050327

1 任务描述

本次作业围绕支持向量机 (Support Vector Machine, SVM) 的设计与实现展开, 包含两个任务:

任务一 (分类): 基于 MNIST 手写数字数据集, 设计并实现**线性 SVM 与非线性 (核) SVM** 分类器, 完成 10 类手写数字 (0-9) 的分类任务, 并通过核函数对比与超参数网格搜索分析核函数、惩罚系数 C 、带宽 γ 对性能的影响。评价指标为分类准确率, 并辅以支持向量数量、混淆矩阵进行分析。

任务二 (回归): 基于波士顿房价 (Boston House Prices) 数据集, 设计一个以**支持向量回归 (SVR)** 为核心的回归系统, 根据 13 个房屋/区域特征预测房价中位数。评价指标为测试集均方误差 (MSE)、均方根误差 (RMSE)、平均绝对误差 (MAE) 与决定系数 R^2 , 并与线性回归、线性 SVR 以及作业 2 的 MLPNN 回归结果对比; 另用 5 折交叉验证评估模型稳定性。

实验环境: NVIDIA A100 (80GB) GPU (本次实验均在 CPU 上完成), scikit-learn 1.9.1, Python 3.11。

2 数据描述

2.1 MNIST 数据集

MNIST 包含 70000 张 28×28 的灰度图像, 其中训练集 60000 张、测试集 10000 张, 每张图像对应 0 ~ 9 的一个数字标签, 各类别样本数量大致均衡 (与作业 1、2 相同)。实验直接使用官方训练/测试划分; 调参时从训练集中分层随机留出 5000 张作为验证集。

考虑到核 SVM 的训练复杂度约为训练样本数的平方至立方, 为控制训练开销, 核函数对比实验统一使用从训练集随机抽取的 10000 样本子集 (等价评估集为测试集中的 5000 样本子集); RBF SVM 网格搜索在 10000 样本上进行, 确定最优超参数后再在 20000 样本子集上重训并在完整测试集 (10000 张) 上评估; 线性 SVM (LinearSVC, primal 求解器) 复杂度随样本数近似线性, 直接在完整 60000 训练集上训练。

2.2 波士顿房价数据集

与作业 2 使用完全相同的波士顿房价数据集 (506 样本 $\times$ 13 特征, 回归目标 MEDV 取值 5.0-50.0, 均值约 22.5 千美元), 并采用完全相同的 64%/16%/20% 随机划分 (训练集 323 / 验证集 80 / 测试集 103, 随机种子 42), 以保证与作业 2 的 MLPNN 回归结果可以直接对比。5 折交叉验证覆盖全部 506 个样本。

3 数据预处理

3.1 MNIST

将 28×28 图像展平为 784 维向量并把像素值由 $[0, 255]$ 缩放到 $[0, 1]$ 。特征缩放对 SVM 至关重要：核函数依赖样本间内积/距离，若各维量纲悬殊，大数值维度会主导核函数值。对于 RBF SVM 实验，额外使用 PCA 将 784 维降至 50 维（在 10000 训练子集上 fit，保留 82.5% 方差），以平衡训练速度与信息损失：

```
1 # PCA 降维（仅在训练子集上 fit）
2 pca = PCA(n_components=50, random_state=args.seed).fit(X_sub)
3 Xp = pca.transform(X_train) # 60000 x 50
4 Xp_test = pca.transform(X_test) # 10000 x 50
```

3.2 波士顿房价

对每个特征做 Z-score 标准化（均值、标准差仅在训练集上计算，避免数据泄漏）；回归目标同样先标准化再训练，评估时还原为原始量纲（千美元）。对 SVR 而言标签标准化同样重要： ε -不敏感损失的容忍区间大小是相对于标签量纲定义的，标准化后 ε 的取值（0.01–0.3）才有统一含义。预处理代码与作业 2 一致。

4 算法介绍

4.1 算法原理

线性 SVM（软间隔）。给定训练集 $\{(x_i, y_i)\}_{i=1}^n$, $y_i \in \{-1, +1\}$ ，线性 SVM 求解如下正则化经验风险最小化问题：

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i, \quad \text{s.t. } y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0,$$

其中 hinge 损失 $\xi_i = \max(0, 1 - y_i f(x_i))$ 给出“间隔至少为 1”的软约束， $\frac{2}{\|w\|}$ 为间隔宽度，常数 C 平衡间隔最大化（结构风险）与误分类惩罚（经验风险）。

核方法与非线性 SVM。对原始问题做对偶化后，训练与预测只依赖内积 $x_i^\top x_j$ ，于是可用核函数 $K(x_i, x_j) = \phi(x_i)^\top \phi(x_j)$ 隐式地把样本映射到高维特征空间，决策函数为

$$f(x) = \text{sign}\left(\sum_{i \in \text{SV}} \alpha_i y_i K(x_i, x) + b\right),$$

只有对偶系数 $\alpha_i > 0$ 的支持向量（SV）参与预测。本实验对比线性核 $K = x^\top z$ 、 $d = 3$ 阶多项式核 $K = (x^\top z + 1)^3$ 与高斯（RBF）核 $K = \exp(-\gamma \|x - z\|^2)$ ，其中 γ 控制高斯的影响半径： γ 越大决策边界越“局部”、模型容量越大。

支持向量回归 (SVR)。将 SVM 推广到回归：用 ε -不敏感损失代替 hinge 损失，只惩罚超出“ ε 管道”的残差，

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, |y_i - f(x_i)| - \varepsilon),$$

对偶化后同样可引入核函数 (LinearSVR 与 SVR-RBF)，且解只由管道边界外的支持向量决定，因此对离群点较稳健。

4.2 算法实现

实验基于 scikit-learn 实现 (底层为 libsvm/liblinear)，核心流程如下：线性 SVM 使用 LinearSVC (primal 坐标下降，适合 $n \gg d$ 的大规模问题) 在完整训练集上训练；核 SVM 使用 SVC (SMO 求解对偶问题)。两个任务均按“网格搜索 + 留出验证集选参 + 最优参数重训”的流程实现：

```
1 best = max(grid, key=lambda g: g["val_acc"]) # 验证集选参
2 clf = SVC(C=best["C"], kernel="rbf", gamma=best["gamma"])
3 clf.fit(X_big, y_big) # 最优参数下在更大子集上重训
4 pred = clf.predict(Xp_test) # 完整测试集评估
```

回归任务中 LinearSVR 搜索 $C \times \varepsilon$ 网格 (4×4)，SVR-RBF 搜索 $C \times \gamma \times \varepsilon$ 网格 ($4 \times 4 \times 4 = 64$ 组)，均以验证集 RMSE 选参；5 折交叉验证中每折内部独立做标准化与网格搜索，模拟完整的训练 + 选参流程。

5 实验结果及分析

5.1 实验 5.1: MNIST 分类：线性与非线性 SVM

实验 1 (线性 SVM)。LinearSVC 在完整 60000 训练集上训练， $C \in \{10^{-3}, 10^{-2}, 3 \times 10^{-2}, 10^{-1}\}$ 由 5000 验证集选出。结果： C 从 10^{-3} 增大到 10^{-1} 时验证准确率由 90.54% 单调上升到 92.00%，最优 $C = 0.1$ ，在完整训练集上重训后测试准确率为 **91.82%** (训练总耗时 56 s，测试 0.05 s)。

实验 2 (核函数对比)。在同一 10000 训练子集上 ($C = 1$, $\gamma = \text{scale}$)，线性核 / 3 阶多项式核 / RBF 核在 5000 评估集上的准确率分别为 91.80% / 96.08% / **96.38%**，支持向量数为 2692 / 2886 / 3871，训练耗时 3.7 / 4.3 / 6.1 s。

实验 3 (RBF SVM 网格搜索)。PCA(50) 降维后在 10000 样本子集上搜索 $C \in \{1, 3, 10, 30, 100\} \times \gamma \in \{0.005, 0.01, 0.03, 0.05, 0.1\}$ (图 1)，最优 $C = 30, \gamma = 0.03$ (验证 97.56%)；在 20000 样本上重训后完整测试集准确率达 **98.13%** (5676 个支持向量，重训 3.4 s，测试 3.0 s)。各模型汇总于图 2，混淆矩阵见图 3。




图 1 RBF SVM 网格搜索: $C \times \gamma$ 平面的验证准确率/% (括号内为支持向量数, PCA50 降维、10000 训练子集)




图 2 MNIST 各 SVM 模型准确率对比




图 3 RBF SVM ($C = 30, \gamma = 0.03$, PCA50, 20000 训练) 的测试集混淆矩阵

结论 1: 结果分析如下:

1. 线性 SVM 仅取得 91.82%，说明 MNIST 在原始像素空间中**非线性可分**，需要引入非线性；与之对比，同数据下核 SVM (RBF) 达到 98.13%，验证了核技巧在高维特征空间中构造（近似）线性可分表示的有效性；
2. 核函数对比显示非线性核大幅优于线性核 (+4.6 个百分点)，且 RBF 略优于多项式核；RBF 的支持向量数 (3871/10000) 显著多于线性核 (2692)，说明其决策边界更复杂、更贴合数据分布；
3. 由图 1 可见性能对 γ 更敏感（每列内准确率差异可达 3 个百分点）， $\gamma = 0.005$ 时明显欠拟合、 $\gamma = 0.1$ 时开始过拟合（验证下降且支持向量数激增至约 7000），而 C 增大到一定程度 (≥ 10) 后收益饱和——符合“ C 控制正则强度、 γ 控制模型复杂度量级”的理论预期；
4. 混淆矩阵 (图 3) 显示 187 个错误集中在易混数字对 5→3 (12 次)、7→2 (11 次)、9→4 (10 次)、2→7 (10 次)、4↔9。与作业 2 的 MLP (98.90%) 和作业 1 的 CNN (99.66%) 相比，RBF SVM 仅以 6475 个支持向量系数做推理即达 98.13%，模型紧凑、训练耗时仅约 1 分钟，但准确率低约 0.8–1.5 个百分点，说明对图像数据而言局部卷积结构（权重共享 + 平移先验）优于通用的像素距离核；
5. 训练/推理开销随支持向量数线性增长（线性 SVM 测试 0.05 s vs RBF SVM 3.0 s），这是核 SVM 难以直接扩展到完整 60000 样本乃至更大数据集的主要原因，也是实践中采用 PCA 降维与子采样的动因。

5.2 实验 5.2: 波士顿房价回归: SVR 回归系统

Baseline 为线性回归；对比线性 SVR ($C \times \varepsilon$ 网格: $C \in \{0.1, 1, 10, 100\}$, $\varepsilon \in \{0.01, 0.05, 0.1, 0.3\}$) 与 RBF SVR (再乘 $\gamma \in \{0.01, 0.05, 0.1, 0.5\}$, 共 64 组)，均以验

证集 RMSE 选参。结果见表 1 与图 4、图 5。

表 1 波士顿房价各实验结果对比（与作业 2 同一切分：train/val/test = 323/80/103；RMSE 与 MAE 单位为千美元）

方法	最优超参数	RMSE↓	MAE↓	R^2 ↑
线性回归 (baseline)	—	4.732	3.194	0.6824
LinearSVR	$C = 10, \varepsilon = 0.3$	4.790	2.983	0.6746
SVR-RBF	$C = 100, \gamma = 0.01, \varepsilon = 0.01$	3.070	2.157	0.8663
SVR-RBF (5 折交叉验证)	每折内部重选参	3.497 ± 0.638 0.8445 ± 0.0662		
MLPNN 13-64-32-1 (作业 2)	—	2.922	2.054	0.8789




图 4 (a) LinearSVR 在 C 扫描下不同 ε 的验证 RMSE（虚线为线性回归验证 RMSE）；(b) SVR-RBF 在最优 $\varepsilon = 0.01$ 下 $C \times \gamma$ 平面的验证 RMSE（千美元）；(c) 最优 SVR-RBF 的测试集预测值-真实值散点图




图 5 最优 SVR-RBF 的测试集残差直方图（预测值 - 真实值，千美元）

结论 2： 结果分析如下：

1. LinearSVR（测试 $R^2 = 0.675$ ）与线性回归（ $R^2 = 0.682$ ）几乎持平，说明 ε -不敏感损失本身不提供额外拟合能力，房价数据中的非线性关系必须靠核函数建模；

2. SVR-RBF 将测试 RMSE 由 4.73 降至 3.07 千美元、 R^2 由 0.68 提升至 0.866，显著优于线性模型，接近作业 2 中最佳 MLPNN 的水平 (RMSE 2.92, R^2 0.879)，说明 RBF 核对小样本表格数据的非线性拟合能力与深度模型相当；
3. 由图 4(b) 可见 C 与 γ 存在明显交互： γ 小（核更“平滑”）时需要较大的 C 才能拟合训练数据；最优模型 323 个训练样本中 316 个成为支持向量，说明目标函数存在不可消除的噪声/异方差，几乎全体样本都落在 ε 管道之外；
4. 5 折交叉验证给出 $\text{RMSE} = 3.50 \pm 0.64$ 、 $R^2 = 0.845 \pm 0.066$ ，每折自动选出的超参数集中在 $C = 10\text{--}100$ 、 $\gamma \in \{0.01, 0.05, 0.1\}$ ，与单次划分结果一致，说明结论稳健，但 506 样本的小数据集上折间波动（标准差 0.64）仍明显大于作业 2 MLP 的 CV 结果；
5. 由图 4(c) 与图 5 可见预测点整体紧贴对角线、残差近似以 0 为中心对称分布，但在高价区（MEDV 接近 50 千美元的数据被人为截断）仍有系统性低估，与作业 2 的观察一致。

6 总结

本次作业完整实现了基于 SVM 的分类与回归系统。主要结论：(1) 分类任务中，线性 SVM (91.82%) 无法刻画 MNIST 的非线性结构，RBF 核 SVM 结合 PCA 降维与网格搜索 ($C = 30, \gamma = 0.03$) 在 20000 训练子集上达到 98.13% 测试准确率，核函数与非线性超参数 (γ) 是影响性能的首要因素；(2) 回归任务中，RBF SVR (测试 RMSE 3.07 千美元， $R^2 = 0.866$) 显著优于线性模型并与作业 2 的 MLPNN 接近，5 折交叉验证 (RMSE 3.50 ± 0.64) 确认结果稳健， ε -不敏感损失与标签标准化、验证集选参是小样本回归的关键；(3) 综合来看，SVM/SVR 在中小规模数据上以极低的训练和调参成本（全部分钟级）取得了与神经网络相当的性能，但其训练复杂度随样本数超线性增长、预测开销随支持向量数增长，面对大规模数据需依赖子采样、降维或近似核方法。后续可尝试 Nyström/RFF 近似核以扩展到完整 MNIST，或在回归任务上引入自动相关确定 (ARD) 核做特征选择。