

2026 机器学习

课程报告 4

姓名：徐厚泽

学号：26113050327

1 任务描述

本次作业要求设计一个房价预测回归系统：基于波士顿房价（Boston House Prices）数据集，根据 13 个房屋/区域特征预测房价中位数 MEDV，回归算法必须包含岭回归（Ridge Regression）与 Lasso 回归两种正则化线性模型。

具体完成内容：(1) 从零实现岭回归（解析解）与 Lasso（坐标下降法），并与 scikit-learn 的实现交叉验证；(2) 以最小二乘（OLS）线性回归为 baseline，在 α 网格上搜索正则化强度，用留出验证集 RMSE 选参；(3) 对比两种正则化方式的系数收缩行为与特征选择能力；(4) 在二阶多项式特征（13 维 $\rightarrow$ 104 维）上进一步对比 OLS/Ridge/Lasso，考察正则化在高维特征下的作用；(5) 用 5 折交叉验证评估结论的稳健性，并与作业 2（MLPNN）、作业 3（SVR）的回归结果对比。

评价指标为测试集均方根误差（RMSE）、平均绝对误差（MAE）与决定系数 R^2 （原始量纲：千美元）。实验环境：Python 3.11，NumPy 2.4.6，scikit-learn 1.9.1，全部实验在 CPU 上完成。

2 数据描述

使用与作业 2、作业 3 完全相同的波士顿房价数据集（Kaggle / scikit-learn 经典版本）：共 506 个样本，每个样本含 13 个输入特征与 1 个回归目标 MEDV（自住房屋价格中位数，单位千美元，取值 5.0–50.0，均值约 22.5）。13 个特征分别为：crim（人均犯罪率）、zn（大面积住宅用地比例）、indus（非零售商业用地比例）、chas（是否临查尔斯河）、nox（氮氧化物浓度）、rm（平均房间数）、age（老旧房屋比例）、dis（到就业中心加权距离）、rad（公路可达性指数）、tax（财产税率）、ptratio（生师比）、b（黑人比例变换量）、lstat（低收入人口比例）。

数据划分沿用作业 2/3 的方案：按随机种子 42 随机划分为训练集 323 / 验证集 80 / 测试集 103（64%/16%/20%），以保证与前两次作业的回归结果可直接对比；5 折交叉验证覆盖全部 506 个样本。

3 数据预处理

对每个特征做 Z-score 标准化，均值与标准差仅在训练集上计算，再用同样的统计量变换验证集与测试集，避免数据泄漏。标准化对正则化回归至关重要：惩罚项 $\alpha\|w\|_2^2 / \alpha\|w\|_1$ 对所有维度一视同仁，若各维量纲悬殊，则大数值维度的系数会被不公平地重罚。与作业 3 的 SVR 不同，岭回归与 Lasso 的目标函数关于标签是二次/ ℓ_1 的，标签无需标准化，直接以原始量纲（千美元）训练并评估；截距通过样本居中单独估计，不参与正则化惩罚。

```
1 x_mean, x_std = X[tr].mean(0), X[tr].std(0) + 1e-8
2 Xs = (X - x_mean) / x_std      # 训练/验证/测试共用训练集统计量
3 return {"X_train": Xs[tr], "y_train": y[tr], ...}
```

多项式特征实验在上述标准化特征基础上做二阶展开(PolynomialFeatures(degree=2), 含全部平方项与交叉项, 13 维 $\rightarrow$ 104 维), 展开后各列量纲再次悬殊, 因此对展开后的特征按训练折统计量再做一次 Z-score 标准化。

4 算法介绍

4.1 算法原理

最小二乘 (OLS, baseline)。求解 $\min_{w,b} \|y - Xw - b\|^2$, 有闭式解但无任何正则化; 当特征间存在共线性或特征维度较高时, 系数方差大、容易过拟合。

岭回归 (Ridge)。在 OLS 目标上增加 ℓ_2 惩罚:

$$\min_{w,b} \|y - Xw - b\|^2 + \alpha \|w\|^2 \implies \hat{w} = (X_c^\top X_c + \alpha I)^{-1} X_c^\top y_c,$$

其中 X_c, y_c 为居中后的数据 (截距 $b = \bar{y} - \bar{x}^\top \hat{w}$ 单独恢复、不受惩罚)。 α 越大系数收缩越厉害: 所有系数被连续地压向 0 但不会精确等于 0, 从而以少量偏差换取方差的大幅下降, 并能稳定处理共线性特征。

Lasso。将惩罚改为 ℓ_1 范数 (采用 scikit-learn 的目标约定):

$$\min_{w,b} \frac{1}{2n} \|y - Xw - b\|^2 + \alpha \|w\|_1.$$

ℓ_1 惩罚的不可微性使最优解天然具有**稀疏性**: α 足够大时部分系数被精确压到 0, 等价于自动特征选择。该问题无闭式解, 采用**坐标下降法**求解: 每次固定其余坐标, 只对 w_j 优化,

$$w_j \leftarrow \frac{S(\rho_j, \alpha)}{z_j}, \quad \rho_j = \frac{1}{n} x_j^\top (y - b - Xw + w_j x_j), \quad z_j = \frac{1}{n} \|x_j\|^2,$$

其中 $S(\rho, \alpha) = \text{sign}(\rho) \max(|\rho| - \alpha, 0)$ 为软阈值算子—— $|\rho_j| < \alpha$ 时该坐标被置 0, 这正是稀疏性的来源。实际实现沿 α 从大到小的路径用上一解 warm start, 可显著加速收敛。

4.2 算法实现

两种算法均基于 NumPy 从零实现, 并以 scikit-learn 作为参照交叉验证: 在若干 α 下手写实现与 Ridge/Lasso 的系数最大差异分别为 10^{-15} 与 10^{-7} 量级, 验证了实现的正确性。核心代码如下:

```
1 class RidgeClosedForm:      # 岭回归解析解
2     def fit(self, X, y):
3         Xc = X - X.mean(0); yc = y - y.mean() # 居中处理截距
4         A = Xc.T @ Xc + self.alpha * np.eye(X.shape[1])
5         self.coef_ = np.linalg.solve(A, Xc.T @ yc) # 解线性方程组求 w
6
7 class LassoCoordinateDescent: # Lasso 坐标下降
```

```

8     def fit(self, X, y, w_init=None):
9         ...                # 居中、预计算 z_j
10        for it in range(self.max_iter):
11            for j in range(d): # 逐坐标软阈值更新
12                rho = (Xc[:, j] @ r) / n + z[j] * w[j]
13                w[j] = soft_threshold(rho, self.alpha) / z[j]
14                r += Xc[:, j] * (w_old[j] - w[j])
15            if max(abs(w - w_old)) < self.tol: break

```

整体实验流程与作业 3 一致：“网格搜索 + 留出验证集选参 + 最优参数重训”，网格取对数等间隔——Ridge 搜 $\alpha \in [10^{-4}, 10^3]$ (29 个点)，Lasso 搜 $\alpha \in [10^{-4}, 1]$ (25 个点)：

```

1  for alpha in sorted(alphas, reverse=(model == "lasso")):
2      mdl = fit_model(model, X_train, y_train, alpha, w_init)
3      w_init = mdl.coef_          # Lasso 沿路径 warm start
4      grid.append({"alpha": alpha, "val_rmse": rmse(y_val, mdl.predict(X_val))})
5  best = min(grid, key=lambda d: d["val_rmse"]) # 验证集选参后重训评估

```

5 实验结果及分析

5.1 实验 5.1：线性特征上的 OLS / Ridge / Lasso

在 13 维原始（标准化）特征上训练三个模型，Ridge 与 Lasso 以验证集 RMSE 在 α 网格上选参，正则化路径与 RMSE 曲线见图 1，数值结果见表 1。




图 1 (a)(c) Ridge/Lasso 的训练与验证 RMSE 随 α 的变化 (红色虚线为验证集最优 α , 灰色点线为 OLS 验证 RMSE); (b)(d) 对应的系数路径。单条划分下最优 α : Ridge 为 10, Lasso 为 0.1

表 1 波士顿房价各模型结果对比 (与作业 2/3 同一切分: train/val/test = 323/80/103; RMSE 与 MAE 单位: 千美元)

方法	最优 α	RMSE↓	MAE↓	R^2 ↑	非零系数数
OLS (baseline)	—	4.732	3.194	0.6824	13/13
Ridge	10	4.694	3.091	0.6874	13/13
Lasso	0.1	4.663	3.051	0.6917	12/13
OLS + poly2	—	3.876	2.672	0.7869	104/104
Ridge + poly2	17.8	3.245	2.342	0.8507	104/104
Lasso + poly2	0.1	3.337	2.333	0.8421	50/104
Ridge (5 折交叉验证)	每折内部重选参	4.884 ± 0.167		0.7101 ± 0.0393	
Lasso (5 折交叉验证)	每折内部重选参	4.945 ± 0.165		0.7026 ± 0.0402	
MLPNN 13-64-32-1 (作业 2)	—	2.922	2.054	0.8789	—
SVR-RBF (作业 3)	—	3.070	2.157	0.8663	—




图 2 (a) 各模型测试集 RMSE (方块与误差线为原始 13 维特征上 5 折交叉验证的均值 $\pm$ 标准差); (b) 最优正则化模型 Ridge+poly2 的测试集预测值-真实值散点 (灰色三角为 OLS baseline)

结论 1:

1. 三种线性模型的测试集性能非常接近 (Ridge/Lasso 仅比 OLS 略优 0.04–0.07 千美元), 说明在仅 13 维、样本量 323 的情况下 OLS 的过拟合本就不严重, 正则化的收益有限, 但也没有损失;
2. 由图 1(a)(c) 可见典型的偏差-方差权衡: α 过大时训练与验证 RMSE 同时恶化 (欠拟合); 对比 (b)(d) 两幅系数路径, Ridge 的系数随 α 平滑收缩、始终非零, 而 Lasso 的系数被**逐个精确压到 0** ($\alpha = 1$ 时仅剩 2 个非零), 体现了 ℓ_1 惩罚的特征选择能力;
3. 最优 Lasso ($\alpha = 0.1$) 将 indus 的系数压为 0 (OLS 中其系数仅 0.10, 为全特征最小), 保留 12 个特征; 三种模型系数排名一致, $|\text{coef}|$ 最大的始终是 lstat (负向, 约 -4.0)、rad、dis、tax、rm (正向, 约 2.5), 与“低收入人口比例越低、房间数越多房价越高”的直觉相符;
4. 单个系数看, Ridge 把 OLS 中量级冲突的 rad (3.29) 与 tax (-2.65 , 二者高度共线: 公路可达性好的地区税率往往也高) 收缩为 2.37 与 -1.82 , 验证了 ℓ_2 惩罚缓解共线性的作用。

5.2 实验 5.2: 二阶多项式特征上的正则化对比

为了考察正则化在高维特征下的价值, 将特征做二阶多项式展开 (13 维 $\rightarrow$ 104 维, 含平方项与全部两两交叉项, 展开后重新标准化), 此时特征数已达训练样本数 (323) 的约三分之一, OLS 过拟合风险显著增加。同样以验证集 RMSE 选参, 结果见表 1 与图 2。




图 3 Ridge+poly2 的测试集残差直方图（预测值 - 真实值，千美元）

结论 2:

1. OLS+poly2 将测试 RMSE 从 4.73 降至 3.88 (R^2 0.787)，说明房价中确实存在二阶非线性关系；但加入正则化后收益更大：Ridge+poly2 达 **RMSE 3.245**、 R^2 **0.851**，Lasso+poly2 达 RMSE 3.337，分别比同特征下的 OLS 提升 16% 与 14%，充分体现了正则化对高维模型的必要性；
2. Lasso+poly2 在 104 个特征中仅保留 **50** 个非零系数即达到与 Ridge 相当的精度，模型更紧凑、可解释性更强；其选出的主要特征为 lstat、rm、lstat²、tax×lstat、tax×ptratio、tax、nox×rad 等——lstat 的平方项系数为正 (+2.79) 而一次项为负 (-4.25)，刻画了房价随 lstat 增大“先快后慢”下降的非线性饱和形态；
3. 图 2(b) 与图 3 显示 Ridge+poly2 的预测点紧贴对角线、残差近似以 0 为中心对称分布，明显优于 OLS（灰色三角），但在 MEDV=50 处仍系统性低估——该数据集的房价在 50 千美元处被人为截断，这一观测与作业 2/3 一致；
4. 与作业 2、作业 3 的非线性模型对比：Ridge+poly2 (RMSE 3.245, R^2 0.851) 已接近 SVR-RBF (3.070, 0.866) 与 MLPNN (2.922, 0.879) 的水平，而训练只需解一次 104×104 的线性方程组（毫秒级），“特征工程 + 正则化线性模型”是该规模数据上极具性价比的方案。

5.3 实验 5.3: 5 折交叉验证

为检验单次划分结论的稳健性，在全部 506 个样本上做 5 折交叉验证：每折内部独立进行标准化、划分验证集并重新在 α 网格上选参，模拟完整的训练 + 选参流程。

结论 3: 5 折交叉验证下 Ridge 与 Lasso 的 RMSE 分别为 4.884 ± 0.167 与 4.945 ± 0.165 (R^2 约 0.70 ± 0.04)，两者差异远小于折间标准差，再次确认两个模型在原始特征上性能相当；各折自动选出的 α 分布在 10^{-4} – 32 (Ridge) 与 2×10^{-2} – 0.3 (Lasso) 之间，与单次划分选出的 $10 / 0.1$ 相容，说明正则化强度的选择对数据划分不敏感、结论稳健。交叉验证 RMSE 高于单次划分的测试 RMSE，主要来自各折测试子集的样本构成差异 (506 样本的小数据集上折间波动难免，作业 2/3 中也观察到了同样的现象)。

6 总结

本次作业设计并实现了以岭回归与 Lasso 为核心的波士顿房价预测回归系统。主要工作与结论：(1) 从零实现了岭回归的解析解与 Lasso 的坐标下降求解器（含软阈值更新与路径 warm start），与 scikit-learn 的实现差异在 10^{-7} 以内；(2) 在原始 13 维特征上，Ridge ($\alpha = 10$) 与 Lasso ($\alpha = 0.1$) 相比 OLS 只有小幅提升（测试 RMSE 约 4.66–4.73 千美元），但 Lasso 能自动剔除无效特征 (indus)、给出稀疏可解释的模型，系数路径实验清晰展示了 ℓ_1 的“精确置零”与 ℓ_2 的“平滑收缩”这两种正则化行为的本质差异；(3) 在二阶多项式特征（104 维）上，正则化的价值充分体现：Ridge+poly2 取得 RMSE 3.245、 R^2 0.851 的全系统最好成绩，比同特征 OLS 提升 16%，接近作业 2/3 中 MLPNN 与 SVR-RBF 的水平而计算开销低数个量级，Lasso+poly2 则以一半的非零系数达到了相当的精度；(4) 5 折交叉验证确认超参数选择与模型对比结论稳健。后续可尝试 ElasticNet ($\ell_1 + \ell_2$ 组合) 在共线性强的高维特征上兼顾稀疏性与分组选择，或用核岭回归直接对比 RBF 核方法。